

刘子阳 Ziyang Liu

15281480053 · ziyang.liu.r@outlook.com · ziy.bio

教育经历

新加坡国立大学，软件工程硕士，新加坡	2026.08 – 2027.11
电子科技大学，软件工程学士，中国成都	2020.09 – 2024.06

工作经历

SmartX，虚拟化研发工程师，中国成都	2024.07 – 2025.09
----------------------	-------------------

V2V OS (1.6.0 至 1.7.2)

- **产品研发**：主导了产品设计与研发，实现了 VMware 到 SMTX OS 及 SMTX OS 集群间的虚拟机迁移。基于 VMware CBT 传输快照，以 Python 实现了控制面、C 实现了数据传输模块并封装为共享库。累计迁移 10,000+ 台生产虚拟机，覆盖金融核心业务。
- **传输吞吐**：重构了串行读写路径，实现了分块异步流水线：收发两侧各使用 8 个线程，并通过共享队列衔接，将持续吞吐从 70 MB/s 提升至 290 MB/s。
- **VDDK 版本隔离**：将多线程迁移任务重构为一任务一进程，使各进程独立加载对应 VDDK，显著扩大了 vSphere 版本覆盖范围。
- **驱动注入挂载**：改造了 V2V OS 驱动注入的磁盘挂载方式，以 iSCSI 替代 NFS，解决了客户机挂起问题；并将迁移流程适配至 SMTX ELF 存算分离集群。

SMTX OS / ELF

- **VMTools**：重构了客户机内 Agent，将原先通过 QGA guest-exec 调用 shell 脚本的执行方式改为 QGA 原生命令，并实现了资源采集探针。调用延迟从 3 秒降至 50 毫秒以内，年度客户升级工单从 40 起降至 5 起以内。
- **文件系统一致性快照**：在原有崩溃一致性快照上研发了文件系统一致性能力。实现了控制面经 VMTools 调用客户机内的 fsfreeze 与 thaw，在快照前冻结文件系统、完成后解冻，保证快照中的文件系统状态一致。
- **跨集群热迁移校验**：参与开发了 SMTX OS 跨集群虚拟机热迁移，并实现了基于 libvirt hook 的迁移后数据一致性校验。校验前调用存储 API 创建磁盘快照；源、目标端分别对磁盘分块并异步计算 block hash，通过各自的递增序列队列保持比对顺序。源端 block reader 生成任务，writer/verifier 与目标端校验服务通信并比对 hash，校验过程不阻塞虚拟机 switchover。
- **客户机内核缺陷**：定位并推动修复了两项客户机内核缺陷：通过 strace 发现 UOS 内核创建 pidfd 后未回收导致虚拟机挂起，缺陷以金融行业通报发布，修复后收到客户感谢信；另发现老内核未持续轮询 QGA 串口 fd，导致宿主机下发的 JSON 被静默截断。

SmartX，虚拟化研发实习生，中国成都	2022.10 – 2024.07
----------------------	-------------------

- **V2V OS (1.2.0 至 1.6.0)**：研发了基于 openEuler 的 virtual appliance，将迁移服务封装为独立系统以满足政府采购要求；重新编译了内核，启用新版客户机文件系统所需特性。
- **增量同步**：实现了不停机多轮增量同步，替代“全盘复制后停机补齐变更”的旧流程；基于 VMware CBT 定位变化块，减少了最终停机阶段的数据传输量。
- **打包与发布**：实现了 V2V 及其内核的 RPM 打包，搭建了可引导 ISO 的 CI/CD 装配流程，并使用 Packer 构建了 vSphere OVF 镜像。
- **驱动注入**：实现了 Linux 与 Windows 离线驱动注入：Linux 侧重打包 initramfs；Windows 侧用 procmon 录制并离线重放 virtio-win 注册表差异，覆盖 MBR 与 UEFI；失败时通过磁盘快照回退至 IDE。
- **系统兼容性**：扩展了驱动注入与 VMTools 的系统兼容性，覆盖包括 openEuler、UOS 和麒麟在内的九个 Linux 发行版，以及 Windows Server 2012 至 2025。

字节跳动（飞书），系统集成开发实习生，中国成都	2022.06 – 2022.09
-------------------------	-------------------

- **流程集成**：使用 Go 和 Gin 研发了集成服务，将招聘流程接入外部 OA 系统，并以 MongoDB 持久化同步状态与重试记录。
- **接口加固**：实现了接口鉴权与限流，并补充了完整的回归测试。

项目经历

FastMM，维护者，C++20 做市交易引擎，[ziy.bio/FastMM](#)

2026.09 – 至今

- **C++ 热路径**：设计了由单个交易线程持有全部状态的引擎架构，热路径无需加锁，其他线程通过无锁队列传递消息；将行情更新到生成订单的耗时缩短至 159 ns，启动后不再分配内存。
- **实盘交易**：使用真实资金在币安运行了做市策略，以 1 万美元本金实现日成交额 35 万美元以上，前 4 天发出 250 万笔订单，从价格更新到发出订单的中位延迟为 8.7 μ s。
- **实盘延迟排查**：定位了实盘中订单在引擎内排队 2–6 ms 的问题，原因是每次余额更新都让 85 个交易对全部重新报价；改为每批消息只重新报价一次，将余额处理 p99 从 23.8 μ s 降至 1.2 μ s。
- **CPU 争用**：定位了 2 vCPU 云主机上 6 个忙等线程争抢 CPU 的问题；将空闲线程由自旋改为主动让出 CPU，延迟 p50 从 2.5 ms 降至 0.23 ms，p99 从 7.0 ms 降至 0.49 ms。
- **行情接入**：将币安行情从 JSON 切换为二进制格式，解码耗时从 680 ns 降至 51 ns；实现了 7 家加密货币交易所及 Nasdaq 连接器，以及 AF_XDP、DPDK 内核旁路接收。
- **回测准确性**：实现了回测与实盘共用同一份策略代码，重放结果完全可复现；改用录制的到达时间与真实延迟回放，将回测中被打穿成交的占比从 2.6% 校正到 16.0%（实盘 17.2%）。
- **Python**：实现了 Python 策略接口，由 Numba 将关键路径编译为机器码，并以 [fastmm-engine](#) 发布到 PyPI。
- **实时看板**：使用 Rust 实现了实盘交易网页看板 bndesk（[源码](#)、[演示](#)），展示各子账户的分来源盈亏、成交质量、报价与库存；服务端只推送变化的数据。实盘演示可邮件联系获取。

研究经历

香港科技大学（广州），研究员

2025.09 – 2026.08

ICLR 2027 在投

- Z. Liu, Y. Shi. A Simpson’s Paradox in In-Context Learning Curves. 发现常用的上下文学习曲线存在 Simpson’s paradox：总体 loss 随位置下降，但在每个 token 出现次数组内反而上升；在八个领域、两个 Pythia 规模上，领域解释了标准指标 99% 的方差，模型规模仅解释 0.2%。
- Y. Shi, Z. Liu, K. Luo, N. Tang. A Living In-the-Wild Benchmark for Measuring the Static-Benchmark Gap in AI-Generated Video Detection. 构建含 21,504 个真实平台视频的 VidTide；五类检测器由已发表的 93–96% AUROC 降至 52–71%，量化了静态基准与真实分布之间的差距。
- Y. Shi, K. Luo, Z. Liu, N. Tang. Neuro-Symbolic Forensic Reasoning for Open-Generator AI-Generated Video Detection. 提出无需训练检测器权重的 FOVEA，以 VLM 规划取证假设、确定性 CV 工具验证证据，在十个未见生成器上达到 97.39% accuracy 与 0.99 AUROC。

准备中

- **Committed SAE-feature traces**：针对托管模型 API 可能用低成本模型替换声明模型、用户难以审计的问题，设计了模型身份验证方案：以稀疏自编码器 (SAE) 特征轨迹生成响应指纹，并在抽查前提交 Merkle root，防止服务方事后篡改证据。实现了对三个骨干模型上 17 个替换模型的全部检出，开销低于 2.1%。
- **Cooperative memory paging**：针对长对话超出上下文窗口后早期信息被截断的问题，设计了由模型主动取回内容的 memory paging。验证了模型缺失事实时不会呈现更高的 token-level uncertainty，进而为移出上下文的内容保留约 8 个 token 的关键词书签，并实现了 recall() 工具按需取回全文。在 LoCoMo 上优于五种方法，四个 LLM judge 结论一致， $p = 0.017$ 。
- **Copy-as-decode**：针对 LLM 编辑文件时仅修改少量内容、却需重新生成整份文件的 decoding 开销，设计了 copy-as-decode：由模型标记待复制的输入行，经一次并行 prefill 写入 KV cache；复用了 speculative decoding 的验证流程，以输入文档作为 draft，并通过语法约束保证复制内容被接受。单次编辑中 74% 到 98% 为复制内容，理论加速上限为 13 $\times$ 。

技能

编程语言	Python、C++、C、Rust、Go、Shell
网络与 I/O	TCP/UDP 组播、epoll、io_uring、AF_XDP、DPDK、tcpdump
Linux/UNIX	进程与线程、虚拟内存、NUMA、CPU affinity、cgroups、strace/perf/gdb
虚拟化与迁移	QEMU/KVM、libvirt、Virtio、VMware CBT/VDDK、QGA、热迁移
LLM 系统	记忆分层、召回与重排、ReAct、MCP、KV cache
构建与运维	CMake、GitHub Actions、Jenkins、Docker、RPM/DEB、Packer
数据库	MySQL、Redis、MongoDB、SQLite

荣誉

中国大学生计算机设计大赛全国三等奖（2022） | 电子科技大学奖学金（2020–21）